

Relatório Técnico — HealthSearch

UNIPÊ — Tendências em Ciência da Computação | Alunas: Anna Maria, Maria Eduarda e Milena Azevêdo

1. Arquitetura da Solução

O HealthSearch é um motor de busca híbrido para um corpus médico de 6 documentos, implementado em Python/Streamlit em um único arquivo (healthsearch_app.py). O pipeline segue quatro etapas: (1) ingestão e pré-processamento do corpus, (2) ranking léxico via BM25, (3) ranking semântico via embeddings, e (4) fusão dos dois rankings por Reciprocal Rank Fusion (RRF), exibidos em uma interface com controles interativos e abas comparativas.

2. Ingestão e Pré-processamento (Fase 1)

O corpus foi carregado de forma estática em um dicionário Python (6 documentos clínicos). O pré-processamento aplica minúsculas, remoção de caracteres especiais via regex (preservando acentos e hífens) e remoção de stopwords em português (NLTK), gerando o corpus_tokenizado reaproveitado tanto para indexar documentos quanto para tokenizar consultas. A regex preserva códigos técnicos como "CÓD-ECG-12D" intactos, essenciais para a precisão do BM25.

3. Motor Léxico BM25 (Fase 2)

Implementado com rank_bm25 (BM25Okapi) sobre o corpus tokenizado, com sliders de k1 (0–3, padrão 1.2) e b (0–1, padrão 0.75) recalibráveis em tempo real sem reconstruir o índice. O carregamento das stopwords foi cacheado (@st.cache_resource) para evitar downloads repetidos a cada interação do Streamlit. Teste: a busca por "infarto" recupera o Doc 2 (score 1.32) mas não o Doc 1 ("síndrome coronariana", score 0.0) — limite léxico que motiva a Fase 3.

4. Motor Semântico Vetorial (Fase 3)

Utiliza sentence-transformers com o modelo multilíngue paraphrase-multilingual-MiniLM-L12-v2, leve o bastante para rodar em CPU. Documentos e consulta são convertidos em vetores densos normalizados; a relevância é medida por similaridade de cosseno, capturando relações de significado que o BM25 ignora. Os embeddings do corpus são cacheados (@st.cache_resource), calculados uma única vez por sessão. Teste: a busca por "infarto" recupera tanto o Doc 2 quanto o Doc 1, corrigindo a lacuna léxica — mas dilui a precisão em buscas por códigos técnicos exatos.

5. Fusão por Reciprocal Rank Fusion (Fase 4)

O RRF combina os rankings do BM25 e do semântico pela fórmula $\text{Score}(D) = \alpha \cdot [1/(k + \text{RankBM25})] + (1 - \alpha) \cdot [1/(k + \text{RankSemântico})]$, com $k=60$ (constante de suavização da literatura original, Cormack et al. 2009). O slider de α controla o peso relativo ($\alpha=1 \rightarrow$ BM25 puro; $\alpha=0 \rightarrow$ semântico puro; $\alpha=0,5$ padrão). Documentos ausentes em um ranking recebem posição N+1, penalizados sem serem eliminados.

6. Interface Integrada e Resultado

A interface reúne os três motores em quatro abas (Léxico, Semântico, Híbrido RRF, Matriz Comparativa), com sidebar de controles e destaque visual (st.success) para o melhor resultado de cada aba. Teste decisivo: a busca por "ataque cardíaco" (termo ausente do corpus) retorna score 0.0 em todo o BM25, enquanto o semântico recupera corretamente os documentos sobre infarto/síndrome coronariana; com $\alpha=0,5$, o RRF posiciona esses documentos no topo, confirmando a fusão funcionando como interpolação ponderada.

7. Matriz Comparativa de Ranks




Figura 1 – Comparação de posições nos três rankings (BM25, Semântico e Híbrido RRF) para a consulta "ataque cardíaco".

8. Divisão de Tarefas

Aluna	Responsabilidade
Maria Eduarda	Fase 1 (Ingestão e Pré-processamento) e Fase 2 (Motor Léxico BM25)
Milena Azevêdo	Fase 3 (Motor Semântico Vetorial)
Anna Maria	Fase 4 (Fusão RRF), Matriz Comparativa e integração final do healthsearch_app.py

9. Conclusão

O HealthSearch demonstra, na prática, que motores de busca léxico e semântico são complementares, não substitutos: o BM25 garante precisão em termos técnicos exatos (como códigos de exame), enquanto o modelo semântico recupera documentos clinicamente relevantes mesmo sem sobreposição literal de palavras. A fusão por Reciprocal Rank Fusion consolidou essas duas forças em um único ranking ajustável, validando a arquitetura híbrida proposta no desafio.